

Relatório de Evolução — Sprint 03

Projeto ChargeGrid Intelligence — EV Challenge GoodWe (FIAP, Grupo 7)

1. Resumo da evolução (Sprints 1/2 → Sprint 03)

Nas Sprints 1 e 2, o chatbot GoodWe/ChargeGrid era implementado como uma sequência manual de chamadas à API do LLM: uma função Python concatenava o system prompt, o histórico (mantido em uma lista comum) e a pergunta do usuário a cada turno, sem orquestração formal, sem guardrails testados sistematicamente e sem comparação objetiva entre modelos. Na Sprint 03, o núcleo conversacional foi refatorado para usar o framework de agentes **LangGraph**: o fluxo passou a ser modelado como um grafo de estados (*StateGraph*), a memória por sessão passou a ser gerenciada por um checkpointer nativo (*MemorySaver*), e uma suíte automatizada de testes funcionais, de memória e de segurança passou a ser executada contra múltiplos provedores de LLM (OpenAI e Google Gemini), com resultados exportados para `relatorio_modelos.md`.

2. Refatoração — decisões técnicas e trade-offs

Framework escolhido: LangGraph, por permitir modelar o agente como grafo de estados, oferecer checkpointer nativo para memória por sessão e ser agnóstico ao provedor de LLM (bastando trocar o objeto *ChatModel* injetado no nó do agente). Essa escolha viabilizou diretamente o requisito de comparação entre modelos, já que a mesma orquestração roda tanto sobre ChatOpenAI quanto sobre ChatGoogleGenerativeAI.

Principais trade-offs: (1) curva de aprendizado maior do que a versão manual das Sprints 1/2; (2) o checkpointer padrão (*MemorySaver*) mantém a memória apenas em RAM — suficiente para a demonstração da sprint, mas não persistente entre reinícios do kernel; (3) depender de uma biblioteca de terceiros introduz risco de *breaking changes* entre versões, mitigado fixando as versões no `pip install`.

3. Comparativo antes × depois

Aspecto	Sprints 1/2 (manual)	Sprint 03 (LangGraph)
Arquitetura	Chamada manual e sequencial à API (função Python <code>generate_dialogue</code>)	Script de orquestração em <i>StateGraph</i> + checkpointer), reutilizável entre sessões
Memória	Lista Python em memória local, montada manualmente	Gerenciada pelo <i>MemorySaver</i> (thread_id, testada e validada)
Seleção de modelo	Escolha ad hoc (GPT-4o-mini), sem suíte comparativa	Baseada em suíte automatizada — modelo escolhido: gemini-2.5-flash (T=0.3)
Testes de segurança	Não formalizados (nenhum caso de Prompt Injection)	Focalizados e automatizados (Prompt Injection, escopo, jurídico, financeiro, elétrico)
Medição de latência/tokens	Qualitativa apenas ('Gemini mais rápido ~1-2s, GPT ~2s')	Quantitativa padronizada — latência média mínima observada: 0.76 s (gemini-2.5-flash)
Nº de casos de teste funcionais	5 (avaliação manual: Adequada/Parcialmente/Inadequada)	40 (avaliação automática por palavra-chave: OK/REVISAR)

Resultados quantitativos da suíte automatizada (execução real, Seção 7 do notebook):

Modelo/config.	Latência média (s)	Tokens médios (aprox.)	Taxa de sucesso
gemini-2.5-flash (T=0.3)	0.76	32.5	83.3%
gpt-4o-mini (T=0.3)	1.4	48.0	83.3%
gpt-4o-mini (T=0.9)	1.67	63.08	83.3%

Modelo escolhido para a versão final: gemini-2.5-flash (T=0.3), com base na maior taxa de sucesso combinada (testes funcionais + memória + segurança) da suíte automatizada — decisão orientada por dados, e não por preferência do grupo. Detalhamento completo em `relatorio_modelos.md`.

4. Problemas encontrados e soluções

Problema 1 — Memória perdida entre execuções de célula

Alternativas consideradas: Alternativas: (a) variável global manual; (b) checkpointer persistente em disco/banco; (c) MemorySaver do LangGraph em RAM.

Solução adotada: Adotado (c): MemorySaver indexado por thread_id.

Justificativa: Atende ao requisito de memória por sessão com baixa complexidade; persistência em disco fica fora do escopo de uma demonstração local.

Problema 2 — Avaliar guardrails de forma objetiva

Alternativas consideradas: Alternativas: (a) leitura manual de cada resposta; (b) um segundo LLM como juiz; (c) checagem determinística por palavras-chave.

Solução adotada: Adotado (c): heurística por palavras-chave, com revisão manual dos casos sinalizados.

Justificativa: Reprodutível e sem custo/latência extra de um LLM avaliador; suficiente para o volume de testes da sprint.

Problema 3 — Comparar modelos de provedores diferentes de forma justa

Alternativas consideradas: Alternativas: (a) comparação subjetiva 'na sensação'; (b) mesma suíte e mesmos parâmetros para todos os provedores, variando só o modelo.

Solução adotada: Adotado (b): suíte e parâmetros fixos, com experimento isolado de temperature.

Justificativa: Garante que diferenças observadas sejam atribuíveis ao modelo, não a perguntas/parâmetros distintos, tornando a escolha final defensável com dados.

5. Divisão da equipe

Nome	RM	Principal responsabilidade
Renan Fracalossi Mano da Silva	569610	Engenharia de Agentes (Dev Core) — arquitetura LangGraph e memória
Gabriel Barbosa Furin	572941	Guardrails e testes de segurança (Prompt Injection e escopo)
Gabriel de Almeida Santos	569395	Comparação entre modelos — harness de testes e relatorio_modelos.md
Herbert Soares de Jesus	571507	Interface de chat e integração da base de conhecimento
Lucas Kiodi Moraca	571004	Documentação, comparativo antes x depois e relatório de evolução

Relatório gerado automaticamente a partir dos resultados reais da execução da Seção 7 deste notebook.